优化方法

2026，秋季

第四章 对偶理论

目录

1. 共轭对偶
2. Lagrange对偶
3. 对偶理论的应用
4. proximal gradient method

1 共轭对偶

- 问题与最优值函数
- 共轭对偶理论

问题与最优值函数

设X, U与Y是有限维Hilbert空间, X^*, U^*与Y^*分别是它们的共轭空间, 则(X, X^*), (U, U^*)与(Y, Y^*)分别是成对的空间.

问题与最优值函数

考虑最优化问题

$$(\mathrm{P}) \qquad \min_{x \in X} f(x),$$

其中$f : X \to \overline{\Re}$. 问题(P)被嵌入到下述一族问题

$$(\mathrm{P}_u) \qquad \min_{x \in X} \varphi(x, u),$$

中, 其中u是参数, $\varphi : X \times U \to \overline{\Re}$, 设$u = 0$对应的问题$(\mathrm{P}_0)$与(P)相同, 即$\varphi(\cdot, 0) = f(\cdot)$, 注意不限定$f$或$\varphi$是凸函数. 与原始问题$(\mathrm{P}_u)$相联系的最优值函数是

$$\nu(u) = \inf_{x \in X} \varphi(x, u).$$

最优值函数的共轭

若$f(\cdot)$的定义域($\varphi(\cdot,u)$的定义域)是非空的, 则称问题(P)(问题(P_u))是相容的. 显然, (P_u)是相容的充分必要条件是$\nu(u) < +\infty$.

基于下述共轭函数来计算$\nu(\cdot)$的共轭函数

$$\varphi^*(x^*,u^*) = \sup_{(x,u)\in X\times U}\{\langle x^*,x\rangle + \langle u^*,u\rangle - \varphi(x,u)\},$$

最优值函数的共轭与双重共轭

$$\nu^*(u^*) \quad = \varphi^*(0,u^*).$$

$$\nu^{**}(u) \;=\; \sup_{u^*\in U^*}\{\langle u^*,u\rangle - \varphi^*(0,u^*)\}.$$

证明:

共轭对偶

这导致下述定义的问题(P_u)的对偶问题:

共轭对偶问题

$$(\mathrm{D}_u) \qquad \max_{u^* \in U^*} \{\langle u^*, u\rangle - \varphi^*(0, u^*)\}.$$

称上述问题(D_u)是(P_u)的共轭对偶. 尤其, 对$u = 0$, 对应的问题(D_0)是

$$(\mathrm{D}) \qquad \max_{u^* \in U^*} \{-\varphi^*(0, u^*)\},$$

为(P)的共轭对偶.

显然有$\mathrm{val}(\mathrm{P}_u) = \nu(u)$, $\mathrm{val}(\mathrm{D}_u) = \nu^{**}(u)$, 因为$\nu(u) \geq \nu^{**}(u)$, 有

$$\mathrm{val}(\mathrm{P}_u) \geq \mathrm{val}(\mathrm{D}_u).$$

非负量$\mathrm{val}(\mathrm{P}_u) - \mathrm{val}(\mathrm{D}_u)$, 当它有意义的时候, 被称为是$(\mathrm{P}_u)$与$(\mathrm{D}_u)$间的对偶间隙.

共轭对偶

由对偶理论的基础性命题(i)可得下述命题：

若$\nu^{**}(u)$是有限的，则(D_u)的最优解集$\mathcal{S}(\mathrm{D}_u)$与$\partial\nu^{**}(u)$相同.

定理1

(i) 对给定的$u \in U$，若次微分$\partial\nu(u)$是非空的，则(P_u)与(D_u)的对偶间隙为零，即$\mathrm{val}(\mathrm{P}_u) = \mathrm{val}(\mathrm{D}_u)$，对偶问题$(\mathrm{D}_u)$的最优解集与$\partial\nu(u)$相同.

(ii) 若$\mathrm{val}(\mathrm{P}_u) = \mathrm{val}(\mathrm{D}_u)$且有限，则$(\mathrm{D}_u)$的最优解集(可能是空集)与$\partial\nu(u)$ 相同.

(iii) 若$\mathrm{val}(\mathrm{P}_u) = \mathrm{val}(\mathrm{D}_u)$且$\bar{x} \in X$与$\bar{u}^* \in U^*$分别是$(\mathrm{P}_u)$与$(\mathrm{D}_u)$的最优解，(从而公共最值是有限的)，则下述最优性条件成立

$$\varphi(\bar{x}, u) + \varphi^*(0, \bar{u}^*) = \langle \bar{u}^*, u \rangle. \tag{1}$$

相反地，若条件(1)对某$\bar{x}$与$\bar{u}^*$成立，则$\bar{x}$与$\bar{u}^*$分别是(P_u) 与(D_u)的最优解，(P_u)与(D_u)不存在对偶间隙.

Proof.

(i) 由Yang–Fenchel不等式, 若$\partial\nu(u)$是非空的, 则

$$\nu(u) = \langle u^*, u\rangle - \nu^*(u^*) \text{ 当且仅当 } u^* \in \partial\nu(u).$$

因为$\nu^*(u^*) = \varphi^*(0, u^*)$, 这意味着$u^*$是$(\mathsf{D}_u)$的最优解的充分必要条件是$u^* \in \partial\nu(u)$, 此种情况$\mathrm{val}(\mathsf{P}_u) = \mathrm{val}(\mathsf{D}_u)$. 因此得到(i).

(ii) 由对偶理论的基础性命题(iii), $\partial\nu^{**}(u) = \partial\nu(u)$, 再由前面的命题得, $\mathcal{S}(\mathsf{D}_u) = \partial\nu^{**}(u)$. 从而得到(ii).

(iii) 若$\mathrm{val}(\mathsf{P}_u) = \mathrm{val}(\mathsf{D}_u)$是有限的, 由上述讨论, 显然$\bar{x} \in X$, $\bar{u}^* \in U^*$分别是(P_u)与(D_u)的最优解当且仅当条件(1)成立. 显然, 若(1)对$\bar{x}$与$\bar{u}^*$成立, 则$\mathrm{val}(\mathsf{P}_u) = \mathrm{val}(\mathsf{D}_u)$, (iii)得证. □

目标函数为凸函数的情况

下述结果表明, 若函数$\varphi(x,u)$是凸的(作为定义在空间$X\times U$上的增广实值函数), 则最优值函数$\nu(u)$是凸的.

最优值函数的凸性

若函数$\varphi(x,u)$是凸的, 则最优值函数$\nu(u)=\inf_x \varphi(x,u)$是凸的.

证明:

目标函数为凸函数的情况

现在设φ是凸的, 因此ν也是凸的. 由Fenchel–Moreau–Rockafellar 定理$\nu^{**} = \mathrm{cl}\nu$. 如果$\mathrm{lsc}\ \nu(u) > -\infty$, 则有$\mathrm{lsc}\ \nu(\cdot) = \mathrm{cl}\ \nu(\cdot)$.

若函数$\varphi(x, u)$是凸的, 则

$$\mathrm{val}(\mathrm{D}_u) = \mathrm{cl}\ \nu(u).$$

进一步, 如果$\mathrm{lsc}\ \nu(u) > -\infty$, 则

$$\mathrm{val}(\mathrm{D}_u) = \mathrm{lsc}\ \nu(u) = \liminf_{u' \to u} \nu(u').$$

若φ是凸的, $\mathrm{lsc}\ \nu(u) > -\infty$, 则$(\mathrm{P}_u)$与$(\mathrm{D}_u)$间没有对偶间隙当且仅当最优值函数$\nu(u)$ 在点u处是下半连续的, 即

$$\nu(u) \leq \liminf_{u' \to u} \nu(u').$$

定义(平稳)

称问题(P_u)是平稳的(calm), 若$\mathrm{val}(\mathsf{P}_u)$有限且最优值函数$\nu(\cdot)$在$u$处是次可微的, 即$\partial\nu(u) \neq \emptyset$.

命题

设$\mathrm{val}(\mathsf{P}_u)$是有限的.若$(\mathsf{P}_u)$是平稳的, 则$(\mathsf{P}_u)$与$(\mathsf{D}_u)$间不存在对偶间隙, 对偶问题$(\mathsf{D}_u)$的最有解集非空.相反地, 若$(\mathsf{P}_u)$与$(\mathsf{D}_u)$间不存在对偶间隙, 对偶问题$(\mathsf{D}_u)$有最优解的充分必要条件是$(\mathsf{P}_u)$是平稳的.

由定理1可证明.

集值映射的概念

定义: 集值映射

设X与U是两个有限维的Hilbert空间, 用2^U表示空间U的所有子集合的全体. 从X到U的一集值映射是X到2^U的一映射, 即对应$x \in X$为一集合$S(x) \in 2^U$, 记为$S : X \rightrightarrows U$或$S : X \longrightarrow 2^U$.

集值映射的概念

集值映射S的定义域, 值域定义为

$$\text{dom } S = \{x \,|\, S(x) \neq \emptyset\}, \text{ range } S = \{u \,|\, \exists x \in X, u \in S(x)\}.$$

集值映射S的逆定义为$S^{-1} : U \rightrightarrows X$, 定义为

$$S^{-1}(u) = \{x \,|\, u \in S(x)\},$$

S下集合C的像是

$$S(C) := \bigcup_{x \in C} S(x) = \{u \,|\, S^{-1}(u) \bigcap C \neq \emptyset\},$$

S下集合D的逆像为

$$S^{-1}(D) = \bigcup_{u \in D} S^{-1}(u) = \{x \,|\, S(x) \bigcap D \neq \emptyset\}.$$

集值映射S的图是$X \times U$的下述子集合

$$\text{gph}\, S = \{(x, u) \,|\, u \in S(x)\}.$$

开映射定理

令X与Y是Banach空间. 泛函分析的一个基本结果是所谓的开映射定理. 被描述为:

开映射定理

若$A : X \to Y$是一连续的线性算子, 它是映上的, 即$A(X) = Y$,
则$0 \in \text{int } A(B_X)$.

由于A是线性的, 其图是一凸集, 由于A是连续的, 其图是闭的. A是映上的条件等价于条件$0 \in \text{int} A(X)$.
现将开映射定理推广到具有闭凸图的多值函数的情形.

广义开映射定理

设X与Y是Banach空间, $S : X \to 2^Y$是一闭凸的集值映射.
令$y \in \text{int}(\text{range } S)$. 则对每一$x \in S^{-1}(y)$及所有的$r > 0$
有$y \in \text{int } S(\mathbb{B}_X(x, r))$.

证明略。

最优值函数连续性的刻画

最优值函数连续性的等价命题

设X与U是有限维Hilbert空间. 设函数$\varphi(x,u)$是正常的, 凸的, 下半连续的, 且$\nu(\bar{u})$是有限的. 则$\nu(u)$在$\bar{u}$处是连续的当且仅当对$\bar{u}$的一个邻域中的所有u, 有$\nu(u) < +\infty$, 即$\bar{u} \in \mathrm{int}(\mathrm{dom}\ \ \nu)$.

凸问题对偶理论的正则条件

设$f : \Re^n \to \overline{\Re}$是一正常凸函数. 若$x \notin \mathrm{dom}\, f$,则$\partial f(x) = \emptyset$.
若$x \in \mathrm{ri}\,(\mathrm{dom}\, f)$, 则$\partial f(x) \neq \emptyset$, $f'(x;y)$是关于y的闭正常函数, 且

$$f'(x;y) = \sup\{\langle x^*, y\rangle \,|\, x^* \in \partial f(x)\} = \sigma(y \,|\, \partial f(x)).$$

进一步, $\partial f(x)$是非空有界的充分必要条件是$x \in \mathrm{int}\,(\mathrm{dom}\, f)$, 此时对每一$y$均有$f'(x;y)$有限.

证明略。

对偶性定理

对偶性定理

设X与U是有限维Hilbert空间. 设函数$\varphi(x,u)$是正常的下半连续凸函数, $\nu(\bar{u})=\mathrm{val}(\mathrm{P}_{\bar{u}})$ 是有限的, 在$\bar{u}\in U$处连续的. 则$(\mathrm{P}_{\bar{u}})$与$(\mathrm{D}_{\bar{u}})$ 间不存在对偶间隙, 集合$\mathcal{S}(\mathrm{D}_{\bar{u}})$非空且等于$\partial\nu(\bar{u})$, 它是$U^*$的非空的凸紧致子集.

证明: 由于$\nu(u)$是凸的, 在$\bar{u}$处是连续的, 由最优值函数连续性的等价命题, $\bar{u}\in\mathrm{int}(\mathrm{dom}\ \ \nu)$. 对于凸问题, 这一正则条件等价于$\partial\nu(\bar{u})$是非空有界. 结合定理1(i)可证得结论.

命题

设X与U是有限维Hilbert空间.设函数$\varphi(x,u)$是正常的, 凸的,下半连续的, 且$\nu(\bar{u})$有限, $\bar{u}\in\mathrm{ri}(\mathrm{dom}\ \ \nu)$.则$(\mathrm{P}_{\bar{u}})$是平稳的.

条件$\nu(u)$在$\bar{u}$处是连续的, 可视为约束规范. 由于空间U是有限维的, $\nu(u)$在$\bar{u}$处是连续的当且仅当$\bar{u}\in\mathrm{int}(\mathrm{dom}\ \ \nu)$, 即对$\bar{u}$的一邻域中的所有的$u$, (P_u)的可行集非空.

2 Lagrange对偶

- Lagrange对偶问题与鞍点
- 两种对偶间的关系

Lagrange对偶问题与鞍点

与参数或扰动形式的对偶相比较, 还有大家更为熟悉的(min-max)极小-极大或Lagrange对偶. 设$K_X \subset X, K_Y \subset Y$是任意非空集合. 与函数$\mathbb{L} : K_X \times K_Y \to \overline{\Re}$ 相联系的原始与对偶问题定义为

$$\min_{x \in K_X} \sup_{y \in K_Y} \mathbb{L}(x, y), \tag{P^L}$$

$$\max_{y \in K_Y} \inf_{x \in K_X} \mathbb{L}(x, y). \tag{D^L}$$

称$\mathbb{L}$是与上述问题相联系的极小-极大对偶性Lagrange函数(min-max duality Lagrangian). 差值$\mathrm{val}(\mathrm{P}^L) - \mathrm{val}(\mathrm{D}^L)$(当它有意义时, 即$\mathrm{val}(\mathrm{P}^L)$与$\mathrm{val}(\mathrm{D}^L)$不取同样的无穷大值) 被称为上述一对对偶问题的对偶间隙.

鞍点

我们称$(\bar{x}, \bar{y}) \in K_X \times K_Y$是函数$\mathbb{L}(x, y)$ 的鞍点(saddle point), 若$\mathbb{L}(\bar{x}, \bar{y}) \in \Re$且

$$\mathbb{L}(\bar{x}, y) \le \mathbb{L}(\bar{x}, \bar{y}) \le \mathbb{L}(x, \bar{y}) \quad \forall (x, y) \in K_X \times K_Y.$$

鞍点与最优解集

(i) 成立着$\mathrm{val}(\mathrm{D}^L) \le \mathrm{val}(\mathrm{P}^L)$, 从而对偶间隙$\mathrm{val}(\mathrm{P}^L) - \mathrm{val}(\mathrm{D}^L)$ 当它有意义时是非负值的.

(ii) 函数$\mathbb{L}(x, y)$有一鞍点的充分必要条件是问题(P^L)与(D^L)具有相同的最优值, 且每一问题具有非空的最优解集. 此种情形, 鞍点集由$\mathcal{S}(\mathrm{P}^L) \times \mathcal{S}(\mathrm{D}^L)$给出.

证明:

两种对偶间的关系

下面来看Lagrange对偶与共轭对偶间的关系. 考虑(P_u): $\min_x \varphi(x,u)$ 及其(共轭)对偶(D_u): $\max_{u^*\in U^*}\{\langle u^*,u\rangle - \varphi^*(0,u^*)\}$. 由于

$$\begin{aligned}\langle u^*,u\rangle - \varphi^*(0,u^*) &= \langle u^*,u\rangle - \sup_{x\in X,u'\in U}\{\langle u^*,u'\rangle - \varphi(x,u')\}\\ &= \inf_{x\in X}\Big(\langle u^*,u\rangle - \sup_{u'\in U}\{\langle u^*,u'\rangle - \varphi(x,u')\}\Big)\\ &= \inf_{x\in X}\Big(\langle u^*,u\rangle - \varphi_u^*(x,u^*)\Big),\end{aligned}$$

其中, 对给定的x, φ_u^*是关于u的偏共轭, 如果我们定义

$$\mathcal{L}(x,u^*,u) := \langle u^*,u\rangle - \varphi_u^*(x,u^*),$$

则(D_u)等价于$(\mathsf{D}_u^{\mathsf{L}})$: $\max\limits_{u^*\in U^*}\inf\limits_{x\in X}\ \mathcal{L}(x,u^*,u)$.

另一方面, 由于

$$\sup_{u^*\in U^*}\ \mathcal{L}(x,u^*,u) = \sup_{u^*\in U^*}\{\langle u^*,u\rangle - \varphi_u^*(x,u^*)\} = \varphi_u^{**}(x,u).$$

两种对偶间的关系

$(\mathrm{D}_u^{\mathrm{L}})$的原始问题为$(\mathrm{P}_u^{\mathrm{L}})$: $\min_{x\in X}\sup_{u^*\in U^*}\mathcal{L}(x,u^*,u)$. 因此, 由于$\varphi_u^{**}\le\varphi$得

$$\begin{aligned}\mathrm{val}(\mathrm{D}_u)=\mathrm{val}(\mathrm{D}_u^{\mathrm{L}})&=\sup_{u^*\in U^*}\inf_{x\in X}\mathcal{L}(x,u^*,u)\le\inf_{x\in X}\sup_{u^*\in U^*}\mathcal{L}(x,u^*,u)\\&=\inf_{x\in X}\varphi_u^{**}(x,u)=\mathrm{val}(\mathrm{P}_u^{\mathrm{L}})\le\inf_{x\in X}\varphi(x,u)=\mathrm{val}(\mathrm{P}_u).\end{aligned}$$

进一步, 若对$\forall x\in X$, 函数$\varphi(x,\cdot)$是凸的且闭的, 则由Fenchel-Moreau-Rockafellar定理得 $\sup_{u^*\in U^*}\mathcal{L}(x,u^*,u)=\varphi(x,u)$, 则原始问题$(\mathrm{P}_u)$可表示为下述形式

$$\min_{x\in X}\{\sup_{u^*\in U^*}\mathcal{L}(x,u^*,u)\}.$$

若$\varphi(x,\cdot)$是一正常的, 凸的, 闭的函数, 则$\mathrm{val}(\mathrm{P}_u^{\mathrm{L}})=\mathrm{val}(\mathrm{P}_u)$. 即此种情形, 共轭对偶性与Lagrange对偶性是重合的.

3 对偶理论的应用

- 对偶与最优性条件
- 凸规划的对偶定理
- 具体问题的对偶问题

原始问题的具体形式

设X, Y是两个有限维Hilbert空间, X^*与Y^*分别是它们的对偶空间. 考虑优化问题

$$(\mathrm{P}) \qquad \min_{x\in X}\{f(x)+F(G(x))\},$$

其中$f: X \to \overline{\Re}, F: Y \to \overline{\Re}$是正常函数, $G: X \to Y$. 上述问题(P)的可行域

$$\Phi = \{x \in \mathrm{dom}\ \ f : G(x) \in \mathrm{dom}\ \ F\}.$$

注意到, 若$F(\cdot) := I_K(\cdot)$是非空集$K \subset Y$的指示函数, 则问题(P)具有下述形式

$$(\mathrm{P}) \qquad \min_{x\in X} f(x) \quad \text{s.t.} \quad G(x) \in K.$$

后面我们将讨论这一特殊情况.

原始问题的嵌入

将(P)嵌入到下述问题族中

$$(\mathrm{P}_y) \qquad \min_{x\in X}\{f(x)+F(G(x)+y)\},$$

其中$y\in Y$被视为参数向量. 显然, $y=0$时, 相应的问题(P_0)即与(P)重合. 问题(P_y)是下述函数关于x的极小化问题

$$\varphi(x,y)=f(x)+F(G(x)+y).$$

记$\nu(y)$为相应的最优值函数, 即$\nu(y)=\mathrm{val}(\mathrm{P}_y)$, 或等价地, $\nu(y)=\inf\limits_{x\in X}\varphi(x,y)$. 注意到, 函数$\varphi(x,u)$的定义域是非空的, 事实上, 因为$f$与$F$是正常的, 则存在$x\in\mathrm{dom}\,(f)$及$y\in\mathrm{dom}\,(F)$.则

$$\varphi(x,y-G(x))=f(x)+F(y)<+\infty,$$

因而$(x,y-G(x))\in\mathrm{dom}\,(\varphi)$. 进一步, $\forall(x,y)\in X\times Y$, $\varphi(x,y)\geq-\infty$, 因而φ 是正常的. 若f与F是下半连续的且G是连续的, 则函数φ是下半连续的. 尤其, 若$F(\cdot):=I_K(\cdot)$是指示函数, 则它是下半连续的当且仅当集合K是闭的.

共轭对偶问题与Lagrange函数

令

$$L(x, y^*) = f(x) + \langle y^*, G(x)\rangle \tag{2}$$

为问题(P)的标准Lagrange函数(standard Lagrangian)(后面我们就称为Lagrange函数).

$$\begin{aligned}\varphi^*(x^*, y^*) &= \sup_{x\in X,\ y\in Y}\{\langle x^*, x\rangle + \langle y^*, y\rangle - f(x) - F(G(x)+y)\} \\ &= \sup_{x\in X}\{\langle x^*, x\rangle - f(x) - \langle y^*, G(x)\rangle \\ &\quad + \sup_{y\in Y}[\langle y^*, G(x)+y\rangle - F(G(x)+y)]\}.\end{aligned}$$

在上述等式中的右端的第二个上确界中作变量替换$G(x)+y \to y$, 得到

$$\varphi^*(x^*, y^*) = \sup_{x\in X}\{\langle x^*, x\rangle - L(x, y^*)\} + F^*(y^*).$$

共轭对偶问题与Lagrange函数

因此, (共轭)对偶问题(D_y)可以写为如下形式(对共轭对偶的一般性的定义: $\max\limits_{y^*\in Y^*}\{\langle y^*, y\rangle - \varphi^*(0, y^*)\}$)

$$(\mathrm{D}_y) \qquad \max_{y^*\in Y^*}\{\langle y^*, y\rangle + \inf_{x\in X} L(x, y^*) - F^*(y^*)\}.$$

尤其, 对$y = 0$, (P)的对偶是

$$(\mathrm{D}) \qquad \max_{y^*\in Y^*}\{\inf_{x\in X} L(x, y^*) - F^*(y^*)\}.$$

与两种对偶性关系讨论中的定义一致, 我们定义Lagrange函数为

$$\mathcal{L}(x, y^*, y) := \langle y^*, y\rangle - \varphi_y^*(x, y^*).$$

共轭对偶问题与Lagrange函数

由于

$$\begin{aligned}
\varphi_y^*(x, y^*) &= \sup_y\{\langle y, y^*\rangle - \varphi(x, y)\} \\
&= \sup_y\{\langle y, y^*\rangle - f(x) - F(G(x) + y)\} \\
&= -f(x) + \sup_y\{\langle y^*, G(x) + y\rangle - F(G(x) + y)\} - \langle y^*, G(x)\rangle \\
&= -L(x, y^*) + \sup_y\{\langle y^*, y\rangle - F(y)\} \\
&= -L(x, y^*) + F^*(y^*),
\end{aligned}$$

所以,

$$\mathcal{L}(x, y^*, y) = \langle y^*, y\rangle + L(x, y^*) - F^*(y^*).$$

最优性条件

最优性条件

若$\mathrm{val}(\mathrm{P}) = \mathrm{val}(\mathrm{D})$, $x_0 \in X$, $\bar{y}^* \in Y^*$分别是(P)与(D)的最优解, 则

$$x_0 \in \arg\min_{x \in X} L(x, \bar{y}^*) \text{ 且 } \bar{y}^* \in \partial F(G(x_0)). \tag{3}$$

相反地, 若条件(3)对点x_0与$\bar{y}^*$成立, 则x_0是(P)的最优解, $\bar{y}^*$是(D)的最优解, (P)与(D)之间没有对偶间隙.

证明:

凸问题的定义

定义: 凸问题

称由$\min_{x\in X}\{f(x)+F(G(x))\}$给出的问题(P)是凸的, 若函数$F(\cdot)$是下半连续的, 函数$f(x)$与$\psi(x,y):=F(G(x)+y)$是凸的.

注:

(1) 若问题(P)是凸的, 则$\varphi(x,y)=f(x)+F(G(x)+y)$是凸的, 因而最优值函数$\nu(y)$也是凸的.

(2) 由$F(G(x)+y)$的凸性可推出函数$F(\cdot)$与$F(G(\cdot))$的凸性. 相反的结论一般来说是不真的, 即$F(y)$与$F(G(x))$的凸性不一定推出函数$F(G(x)+y)$ 的凸性. 例如, 取$F(y)=|y|$及$G(x)=x^2$, $x,y\in\Re$.

凸问题的定义与最优性条件

现在考虑情况$F(\cdot) := I_K(\cdot)$, 其中K是Y的一非空闭凸子集. 此种情况, 问题可以写为

$$(\mathrm{P}) \qquad \begin{array}{ll} \min\limits_{x\in X} & f(x) \\ \text{s.t.} & G(x) \in K \end{array}$$

因为$I_K^*(y^*) = \sigma(y^* \mid K)$, 则相应的对偶问题变为

$$(\mathrm{D}) \qquad \max_{y^*\in Y^*} \{\inf_{x\in X} L(x, y^*) - \sigma(y^* \mid K)\}.$$

凸问题的条件

称问题(P)是凸的, 若函数$f(x)$是凸的, 集合K是闭的, 凸的, 映射$G(x)$相应于集合$C = -K$是凸的.

注: (1) $G(x)$关于$-K$是凸的当且仅当$\psi(x, y) = I_K(G(x) + y)$是凸的. 因为函数$I_K(G(x) + y)$的上图即集值映射$\mathcal{M}(x) = K - G(x)$的图与$\Re_+$的积.
(2) 由于$\partial I_K(y_0) = N_K(y_0)$, 最优条件(3)可表示为

$$x_0 \in \arg\min_{x\in X} L(x, \bar{y}^*) \text{ 且 } \bar{y}^* \in N_K(G(x_0)). \tag{4}$$

凸问题的定义与最优性条件

若集合K是闭凸锥, 则

$$\sup_{y^*\in K^-} L(x,y^*)=\begin{cases} f(x), & 若\ G(x)\in K,\\ +\infty, & 若\ G(x)\notin K.\end{cases}$$

因此, 此种情况, 原始问题具有下述形式

$$(\mathrm{P}) \qquad \min_{x\in X}\sup_{y^*\in K^-} L(x,y^*).$$

此种情况, 若$y^*\in K^-$, $\sigma(y^*\mid K)=0$, 否则$\sigma(y^*\mid K)=+\infty$, 因此对偶问题具有下述形式

$$(\mathrm{D}) \qquad \max_{y^*\in K^-}\inf_{x\in X} L(x,y^*).$$

因此, 对于锥约束, 原始与对偶问题可以通过将"max"与"min"运算应用于Lagrange函数$L(x,y^*)$, 限定y^*属于K^-, 交换它们的顺序得到.
若K是凸锥, 则条件$\bar{y}^*\in N_K(G(x_0))$等价于

$$G(x_0)\in K,\ \bar{y}^*\in K^-\ 且\ \langle \bar{y}^*, G(x_0)\rangle=0.$$

凸规划的对偶定理

凸规划的对偶定理

设X与Y是有限维Hilbert空间. 设$f(x)$是下半连续的, $G(x)$是连续的, 问题(P)是凸的且满足正则性条件

$$0 \in \text{int}\{G(\text{dom } f) - K\}. \tag{5}$$

则问题(P)与(D)间没有对偶间隙, 即$\text{val(P)} = \text{val(D)}$. 进一步, 若(P)的最优值是有限的, 则对偶问题(D)的最优解集是Y^* 的非空凸紧致子集.

凸规划的对偶定理

Proof.

对扰动问题

$$(\mathrm{P}_y) \qquad \min\{f(x) \mid G(x) + y \in K\},$$

其相应的最优值函数ν为$\nu(y) = \inf\{f(x) \mid G(x) + y \in K\}$. 由于问题(P)是凸问题, ν是凸函数. 考虑正则性条件$0 \in \mathrm{int}(\mathrm{dom}\ \ \nu)$, 或等价地, 在0的一邻域上的所有的$y$有$\nu(y) < +\infty$. 而$\nu(y) < +\infty$当且仅当$(\mathrm{P}_y)$具有一可行点$x$满足$f(x) < +\infty$, 即存在$x \in \mathrm{dom}\ \ f$满足$G(x) + y \in K$, 即$\mathrm{dom}\ \ \nu = K - G(\mathrm{dom}\ \ f)$. 所以, 正则性条件$0 \in \mathrm{int}(\mathrm{dom}\ \ \nu)$可以表示为:

$$0 \in \mathrm{int}\{G(\mathrm{dom}\ f) - K\}.$$

由对偶性定理可得结论. □

正则性条件: 广义Slater约束规范

广义Slater约束规范

考虑

$$\min f(x),\ \text{s.t.}\quad \mathcal{A}x - b = 0_l,\ \ g(x) \leq 0_m,$$

其中$f : X \to \Re$是连续的有限凸函数, $\mathcal{A} : X \longmapsto \Re^l$是一连续的线性算子, $g : X \longmapsto \Re^m$是一连续映射, 它的每一分量函数是有限值凸函数. 容易验证上述问题是一凸问题, 如果下述广义Slater约束规范成立:

$$\mathcal{A} \text{ 是映上的，存在一} \bar{x} \in X \text{满足} \mathcal{A}\bar{x} - b = 0_l, g(\bar{x}) < 0_m, \tag{6}$$

则上述问题与它的共轭对偶问题没有对偶间隙.

具体问题的对偶问题

下面给出最优化中常遇到的凸问题的对偶问题的形式.

例: 线性规划

考虑下述线性规划问题

$$(\mathrm{LP}) \qquad \begin{array}{ll} \min & f(x) = c^T x, \\ \text{s.t.} & Ax - b = 0_m, \\ & x \leq 0_n, \end{array}$$

其中$c \in \Re^n$, $A \in \Re^{m\times n}$是行满秩矩阵, $b \in \Re^m$. Lagrange函数定义为$L(x,\lambda) = c^T x + \langle \lambda, b - Ax\rangle$, 上述线性规划问题的Lagrange对偶为

$$\begin{aligned} &\max_{\lambda\in\Re^m} \left\{ \inf_{x\in\Re^n_-} L(x,\lambda) = b^T\lambda + x^T(c - A^T\lambda) \right\} \\ &= \max b^T\lambda \quad \text{s.t.} \quad c - A^T\lambda \leq 0_n. \end{aligned}$$

可见(LP)的对偶问题为 (LD)

$$\begin{array}{ll} \max & b^T\lambda \\ \text{s.t.} & c - A^T\lambda \leq 0_n. \end{array}$$

具体问题的对偶问题

例: 二次规划

考虑下述二次规划问题

$$(\mathrm{QP}) \qquad \begin{aligned} \min \quad & f(x) = c^T x + \frac{1}{2} x^T G x, \\ \text{s.t.} \quad & Ax - b \geq 0_m, \end{aligned}$$

其中$c \in \Re^n$, $A \in \Re^{m \times n}$, $b \in \Re^m$, $G \in \Re^{n \times n}$是一对称正定矩阵. Lagrange函数定义为$L(x, \lambda) = c^T x + \frac{1}{2} x^T G x + \langle \lambda, b - Ax \rangle$, 其Lagrange对偶为

$$\begin{aligned} & \max_{\lambda \in \Re^m_+} \left\{ \inf_{x \in \Re^n} L(x, \lambda) = \frac{1}{2} x^T G x + x^T (c - A^T \lambda) + b^T \lambda \right\} \\ = & \max_{\lambda \in \Re^m_+} \left\{ b^T \lambda - \frac{1}{2} (c - A^T \lambda)^T G^{-1} (c - A^T \lambda) \right\}. \end{aligned}$$

$$(\mathrm{QD}) \qquad \begin{aligned} \max \quad & b^T \lambda - \frac{1}{2} (c - A^T \lambda)^T G^{-1} (c - A^T \lambda) \\ \text{s.t.} \quad & \lambda \geq 0_m. \end{aligned}$$

具体问题的对偶问题

例: 线性半定规划

考虑下述线性半定规划问题

$$\text{(LSDP)} \qquad \begin{array}{ll} \min & f(X) = \langle C, X \rangle, \\ \text{s.t.} & \mathcal{A}X - b = 0_m, \\ & X \in \mathcal{S}^n_+, \end{array}$$

其中$C \in \mathcal{S}^n$是对称阵, $b \in \Re^m$, $\mathcal{A} : \mathcal{S}^n \to \Re^m$是如下定义的线性算子

$$\mathcal{A}X = \Big(\langle A_1, X \rangle, \cdots, \langle A_m, X \rangle \Big)^T,$$

$\mathcal{A}$的伴随算子$\mathcal{A}^* : \Re^m \to \mathcal{S}^n$为

$$\mathcal{A}^* y = \sum_{i=1}^m y_i A_i, \; y \in \Re^m.$$

具体问题的对偶问题

例: 线性半定规划(续)

定义Lagrange函数为$L(X,\lambda)=\langle C,X\rangle+\langle\lambda,b-\mathcal{A}X\rangle$, 对偶问题为

$$\begin{aligned}&\max_{\lambda\in\Re^m}\left\{\inf_{X\in\mathcal{S}^n_+} L(x,\lambda)=b^T\lambda+\langle X,C-\mathcal{A}^*\lambda\rangle\right\}\\&\quad=\max b^T\lambda\quad\text{s.t.}\quad C-\mathcal{A}^*\lambda\in\mathcal{S}^n_+.\end{aligned}$$

可见(LSDP)的对偶问题为

$$\begin{aligned}&\text{(LSDD)}\qquad\qquad\max\quad b^T\lambda\\&\qquad\qquad\qquad\text{s.t.}\quad C-\mathcal{A}^*\lambda\in\mathcal{S}^n_+.\end{aligned}$$

如果下述广义Slater条件成立

$$\mathcal{A}\text{ 是映上的, 且存在}\bar{X}\in S^n_{++}\text{ 满足}\mathcal{A}\bar{X}=b,$$

则(LSDP)与(LSDD)间对偶间隙为0.

具体问题的对偶问题

例: 线性二阶锥优化

考虑下述线性二阶锥优化问题

$$\text{(LSOP)} \qquad \begin{aligned} \min \quad & f(x) = c^T x, \\ \text{s.t.} \quad & A^i x - b^i \in Q_{m_i+1},\ i = 1, \ldots, J, \end{aligned}$$

其中$c \in \Re^n$, $A^i \in \Re^{(m_i+1)\times n}$, $b^i \in \Re^{m_i+1}$, $Q_{m_i+1} \subset \Re^{m_i+1}$是$m_i + 1$维的二阶锥:

$$Q_{m_i+1} = \{(s_0, \bar{s}) \in \Re^{m_i+1} \mid s_0 \geq \|\bar{s}\|\}.$$

Lagrange 函数定义为$L(x, \lambda) = c^T x + \sum_{i=1}^{J} \lambda^{iT}(b^i - A^i x)$.

具体问题的对偶问题

例: 线性二阶锥优化(续)

对偶问题为

$$\max_{\lambda^i \in Q_{m_i+1}} \left\{ \inf_{x \in \Re^n} L(x, \lambda) \right\} = \max_{\lambda^i \in Q_{m_i+1}} \inf_{x \in \Re^n} \left\{ \sum_{i=1}^{J} b^{iT} \lambda^i + x^T \left(c - \sum_{i=1}^{J} A_i^T \lambda^i \right) \right\}$$

$$= \max \sum_{i=1}^{J} b^{iT} \lambda^i \quad \text{s.t. } c - \sum_{i=1}^{J} A_i^T \lambda^i = 0, \lambda^i \in Q_{m_i+1}, i = 1, \ldots, J. \text{ (LSOD)}$$

如果下述Slater条件成立

$$存在 \bar{x} \in \Re^n \text{ 满足} A^i \bar{x} - b^i \in \text{int } Q_{m_i+1}, \forall i = 1, \ldots, J,$$

则(LSOP)与(LSOD)间对偶间隙为0.

具体问题的对偶问题

例: 线性锥优化

设X与Y是有限维Hilbert空间, 考虑下述线性锥优化问题

$$\min f(x) = \langle c, x\rangle, \ \text{s.t.} \quad x \in C, Ax - b \in K,$$

其中$c \in X^*$, $A : X \to Y$是线性算子, $b \in Y$, $C \subset X$与$K \subset Y$是两个闭凸锥. Lagrange 函数定义为$L(x, \lambda) = \langle c, x\rangle + \langle \lambda, Ax - b\rangle$, 上述线性规划问题的Lagrange对偶为

$$\begin{aligned}
&\max_{\lambda \in Y^*} \left\{ \inf_{x \in C} L(x, \lambda) - \sigma(\lambda \mid K) \right\} \\
&= \max_{\lambda \in K^-} \left\{ \inf_{x \in C} L(x, \lambda) \right\} \\
&= \max_{\lambda \in K^-} \left[-\langle b, \lambda\rangle + \inf_{x \in C} \left\{ \langle x, c + A^*\lambda\rangle \right\} \right] \\
&= \max -\langle b, \lambda\rangle \quad \text{s.t.} \quad c + A^*\lambda \in -C^-, \lambda \in K^-.
\end{aligned}$$

具体问题的对偶问题

例: 线性锥优化(续)

如果C与K都是自对偶闭凸锥, 则对偶问题可以表述为

$$\max\langle b, y\rangle \quad \text{s.t.} \quad c - A^* y \in C,\ y \in K.$$

如果C是自对偶闭凸锥, 则对偶问题可以表述为

$$\max\langle b, y\rangle \quad \text{s.t.} \quad c - A^* y \in C,\ y \in -K^-.$$

这一公式可推出例(线性规划)与例(线性半定规划)中的对偶问题.
如果K是自对偶闭凸锥, 则对偶问题可以表述为

$$\max\langle b, y\rangle \quad \text{s.t.} \quad c - A^* y \in -C^-,\ y \in K.$$

这一公式可推出例(线性二阶锥优化)中的对偶问题.

examples

- 给定$A \in \Re^{m\times n}, b \in \Re^m$,考虑

$$\begin{array}{ll} \min\limits_{x\in\Re^n} & x^T x \\ \text{s.t.} & Ax = b \end{array}$$

- 它的对偶问题

$$\max_{\lambda\in\Re^m} -\frac{1}{4}\lambda^T AA^T\lambda - b^T\lambda$$

- 若对偶问题最优解为λ^*,则原问题最优解为$x^* = -\frac{1}{2}A^T\lambda^*$

composite program

- 考虑问题

$$\min_{x \in \Re^n} f(x) + g(x)$$

- 等价地写为

$$\begin{aligned} \min_{x,y} \quad & f(x) + g(y) \\ \text{s.t.} \quad & x - y = 0 \end{aligned}$$

- 它的对偶问题为

$$\min_{\lambda} f^*(-\lambda) + g^*(\lambda)$$

general constrained optimization

- 考虑问题

$$\min_{x\in\Phi} f(x)$$

- 等价地写为

$$\min_{x\in\Re^n} f(x) + 1_\Phi(x)$$

- 它的对偶问题为

$$\min_{\lambda} f^*(-\lambda) + \sigma(\lambda|\Phi)$$

4 proximal gradient method

- proximal mapping
- proximal gradient method

邻近映射(proximal mapping)

- 函数$f:\Re^n\to\bar{\Re}$的*proximal mapping*[1]

$$\mathbf{prox}_{tf}(x)=\arg\min_{u\in\Re^n}\left(tf(u)+\frac{1}{2}\|u-x\|^2\right)$$

  其中$t>0$
- 若f是正常的闭凸函数,则$\mathbf{prox}_{tf}(x)$存在并且唯一
- 若$f(x)=1_C(x)$是闭凸集$C\subseteq\Re^n$的指示函数,则

$$\mathbf{prox}_{tf}(x)=\Pi_C(x)$$

- Moreau分解(Moreau's decomposition):

$$x=\mathbf{prox}_{tf}(x)+t\mathbf{prox}_{f^*/t}(x/t)$$

[1] http://proximity-operator.net/

Weierstrass定理的下半连续版本

Weierstrass定理的下半连续版本

设$K \subset \Re^n$ 为非空紧集, $q : K \to \Re \cup \{+\infty\}$ 为下半连续函数, 且存在$u_0 \in K$ 使$q(u_0) < +\infty$. 则存在$u^* \in K$, 使得

$$q(u^*) = \min_{u \in K} q(u).$$

注：与经典Weierstrass定理相比, 连续性减弱为下半连续性, 结论只保证取到最小值.

凸函数的次微分

设$f:\Re^n \to \Re \cup \{+\infty\}$ 为正常凸函数，定义
域$\mathrm{dom} f = \{x \in \Re^n \mid f(x) < +\infty\}$.
向量$g \in \Re^n$ 称为f 在x 处的一个次梯度，如果

$$f(y) \geq f(x) + g^\top (y - x), \quad \forall y \in \Re^n.$$

f 在x 处所有次梯度构成的集合称为f 在x 处的次微分，记为$\partial f(x)$.
基础性质：

1. $\partial f(x)$ 是闭凸集（可以为空集）；
2. 若f 在x 处可微，则$\partial f(x) = \{\nabla f(x)\}$，退化为单点；
3. 若$x \notin \mathrm{dom} f$，则$\partial f(x) = \emptyset$；
4. 凸函数在$\mathrm{int}(\mathrm{dom} f)$ 内每一点的次微分非空。

凸函数的次微分

考虑无约束问题

$$\min_{x\in\Re^n} f(x),$$

其中f 是正常凸函数.

全局最优充要条件

$\bar{x}$ 是f 的全局极小点当且仅当

$$\mathbf{0} \in \partial f(\bar{x}).$$

证明：$(\Leftarrow)$：若$0 \in \partial f(\bar{x})$，代入次梯度定义：

$$f(y) \geq f(\bar{x}) + 0^\top (y - \bar{x}) = f(\bar{x}), \quad \forall y \in \Re^n,$$

故$\bar{x}$ 是全局极小点。
$(\Rightarrow)$：若$\bar{x}$ 是全局极小点，则对任意y，$f(y) \geq f(\bar{x})$，即

$$f(y) \geq f(\bar{x}) + 0^\top (y - \bar{x}),$$

由次梯度定义，$0 \in \partial f(\bar{x})$。

凸函数的次微分

定义：单调集值映射

集值映射$T:\Re^n \rightrightarrows \Re^n$ 称为是单调的，如果对任意$x_1, x_2 \in \Re^n$，任取$g_1 \in T(x_1), g_2 \in T(x_2)$，都有

$$(g_1 - g_2)^\top (x_1 - x_2) \geq 0.$$

定理

设f 为正常凸函数，则次微分∂f 是单调映射。

证明：任取x_1, x_2，$g_1 \in \partial f(x_1), g_2 \in \partial f(x_2)$。由次梯度定义：

$$f(x_2) \geq f(x_1) + g_1^\top (x_2 - x_1),$$
$$f(x_1) \geq f(x_2) + g_2^\top (x_1 - x_2).$$

两式相加：

$$0 \geq g_1^\top (x_2 - x_1) + g_2^\top (x_1 - x_2) = -(g_1 - g_2)^\top (x_1 - x_2),$$

移项即$(g_1 - g_2)^\top (x_1 - x_2) \geq 0$。

邻近映射的良定义性

定理

设$h:\mathbb{R}^n \to \Re \cup \{+\infty\}$ 为正常的闭凸函数, $t>0$. 对任意$x \in \Re^n$,

$$\text{prox}_{th}(x) = \arg\min_u \left\{ h(u) + \frac{1}{2t}\|u-x\|^2 \right\}$$

存在且唯一.

- 存在性：仿射下界+ 非空紧下水平集+ 下半连续版本的Weierstrass定理.
- 唯一性：凸函数与严格凸二次函数之和严格凸.

邻近映射的良定义性

证明:

固定x，令$\varphi(u) = h(u) + \dfrac{1}{2t}\|u - x\|^2$，该函数具有全局仿射下界（因为它具有强制性）：存在a, b使

$$h(u) \geq \langle a, u \rangle + b, \quad \forall u.$$

配方可得

$$\begin{aligned}
\varphi(u) &\geq \langle a, u \rangle + b + \frac{1}{2t}\|u - x\|^2 \\
&= \frac{1}{2t}\big\|u - (x - ta)\big\|^2 + c, \\
c &= b + \langle a, x \rangle - \frac{t}{2}\|a\|^2.
\end{aligned}$$

取$u_0 \in \operatorname{dom} h$，并设

$$S = \{u : \varphi(u) \leq \varphi(u_0)\}.$$

邻近映射的良定义性

$u_0 \in S$，所以S 非空；且对任意$u \in S$，

$$\left\|u - (x - ta)\right\|^2 \leq 2t\big(\varphi(u_0) - c\big),$$

故S 有界。h 闭意味着φ 下半连续，故S 闭。因此S 为非空紧集。

- 由前述Weierstrass定理，φ 在S 上取到最小值。
- 对$u \notin S$，有$\varphi(u) > \varphi(u_0)$，所以该点也是全局最小值点。
- 因h 凸且二次项严格凸，φ 严格凸，故最小值点唯一。

邻近算子与次梯度的关系

设g 为正常闭凸函数，$t > 0$，令$p = \mathbf{prox}_{tg}(v)$，则

$$p = \arg\min_u \left\{ g(u) + \frac{1}{2t}\|u - v\|^2 \right\}.$$

由凸函数最优性条件，

$$0 \in \partial g(p) + \frac{1}{t}(p - v), \qquad \frac{v - p}{t} \in \partial g(p).$$

邻近映射的非扩张性

设$p = \mathbf{prox}_{tg}(u)$，$q = \mathbf{prox}_{tg}(v)$。由最优性条件，

$$\frac{u-p}{t} \in \partial g(p), \qquad \frac{v-q}{t} \in \partial g(q).$$

由凸函数次微分的单调性，

$$\langle (u-p)-(v-q), p-q \rangle \geq 0.$$

整理得到

$$\|p-q\|^2 \leq \langle p-q, u-v \rangle$$

从而$\|p-q\| \leq \|u-v\|$。

rules

运算法则

- 若$f(x,y)=g(x)+h(y)$,则$\mathbf{prox}_f(x,y)=(\mathbf{prox}_g(x),\mathbf{prox}_h(y))$
- 若$f(x)=g(\lambda x+a)$ $(\lambda\neq 0)$,则

$$\mathbf{prox}_f(x)=\frac{1}{\lambda}(\mathbf{prox}_{\lambda^2 g}(\lambda x+a)-a)$$

- 若$f(x)=\lambda g(x/\lambda)$ $(\lambda>0)$,则

$$\mathbf{prox}_f(x)=\lambda\mathbf{prox}_{g/\lambda}(x/\lambda)$$

examples

- 若$f(x) = 1/2x^T Gx + c^T x$ $(G \succeq 0)$,则

$$\mathbf{prox}_{tf}(x) = (I + tG)^{-1}(x - tc)$$

- 若$f(x) = \|x\|_2$,则

$$\mathbf{prox}_{tf}(x) = \begin{cases} (1 - t/\|x\|_2)x & \|x\|_2 \geq t \\ 0 & \|x\|_2 < t \end{cases}$$

- 若$f(x) = \|x\|_1$,则$\mathbf{prox}_{tf}(x)_i = \mathrm{sign}(x_i)\max(|x_i| - t, 0)$

注:

$$\partial\|x\|_1 = \left\{ s \in \Re^n \;\middle|\; s_i = \begin{cases} 1, & x_i > 0, \\ \in [-1, 1], & x_i = 0, \\ -1, & x_i < 0 \end{cases} \right\}.$$

$$\partial\|x\|_2 = \begin{cases} \left\{ \dfrac{x}{\|x\|_2} \right\}, & x \neq 0, \\ \left\{ s \in \Re^n \mid \|s\|_2 \leq 1 \right\}, & x = 0. \end{cases}$$

proximal gradient method

考虑问题

$$\min_x \ \psi(x) = f(x) + h(x)$$

其中$f : \Re^n \to \Re$是光滑的, $h : \Re^n \to \Re \cup \{+\infty\}$是正常闭凸函数

- proximal gradient method:

$$x^{k+1} = \mathbf{prox}_{t_k h}(x^k - t_k \nabla f(x^k)) \tag{7}$$

- 投影梯度法(projected gradient method) ($h(x) = 1_C(x)$):

$$x^{k+1} = \Pi_C(x^k - t_k \nabla f(x^k))$$

- dual proximal gradient method for

$$\min_\lambda f^*(-\lambda) + h^*(\lambda)$$

收敛性分析

假设4.1

1. f 为凸函数；∇f 在常数L 意义下利普希茨连续，即

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|, \quad \forall x, y;$$

2. h 是正常的闭凸函数(因此prox_{th} 的定义是合理的)；
3. 函数$\psi(x) = f(x) + h(x)$ 的最小值ψ^* 是有限的，并且在点x^* 处可以取到(并不要求唯一)。

以上的条件可以保证邻近梯度法的收敛结果：在定步长$t_k \in (0, \frac{1}{L}]$ 的情况下，迭代点x^k 处的函数值$\psi(x^k)$ 以$O(\frac{1}{k})$ 的速率收敛到ψ^*。

收敛性分析

在正式给出收敛定理之前，我们先引入一个新函数。

定义：梯度映射

设$f(x)$和$h(x)$满足假设4.1，$t>0$为正常数，定义梯度映射为

$$G_t(x)=\frac{1}{t}\big(x-\operatorname{prox}_{th}\big(x-t\nabla f(x)\big)\big). \tag{8}$$

$h\equiv 0$时，$G_t(x)=\nabla f(x)$.

- $G_t(x)$为邻近梯度法每次迭代中的负的“搜索方向”，即
$$x^{k+1}=\operatorname{prox}_{t_k h}\big(x^k-t_k\nabla f(x^k)\big)=x^k-t\,G_t(x^k).$$
- 由邻近算子与次梯度的关系可以得出
$$G_t(x)-\nabla f(x)\in\partial h\big(x-t\,G_t(x)\big). \tag{9}$$
- $G_t(x)=0$当且仅当$0\in\nabla f(x)+\partial h(x)$.
- 若f,h均凸，则上述条件等价于x全局最优解。因此$\|G_t(x^k)\|=0$可以作为停止准则。

收敛性分析

定理：邻近梯度法的收敛性

在假设4.1下，取定步长为$t_k = t \in (0, \frac{1}{L}]$，设$\{x^k\}$是由迭代格式(7)产生的序列，则

$$\psi(x^k) - \psi^* \leq \frac{1}{2kt}\|x^0 - x^*\|^2. \tag{10}$$

证明. 利用假设4.1中的梯度Lipschitz连续性，函数存在二次上界：

$$f(y) \leq f(x) + \nabla f(x)^T(y - x) + \frac{L}{2}\|y - x\|^2, \quad \forall x, y \in \mathbb{R}^n.$$

令$y = x - t\, G_t(x)$，有

$$f\big(x - t\, G_t(x)\big) \leq f(x) - t\, \nabla f(x)^T G_t(x) + \frac{t^2 L}{2}\|G_t(x)\|^2.$$

若$0 < t \leq \frac{1}{L}$，则

$$f\big(x - t\, G_t(x)\big) \leq f(x) - t\, \nabla f(x)^T G_t(x) + \frac{t}{2}\|G_t(x)\|^2. \tag{11}$$

此外，由$f(x)$，$h(x)$ 为凸函数，对任意$z \in \operatorname{dom}\psi$ 我们有

$$h(z) \geq h\big(x - t\, G_t(x)\big) + \big(G_t(x) - \nabla f(x)\big)^T \big(z - x + t\, G_t(x)\big),$$

$$f(z) \geq f(x) + \nabla f(x)^T (z - x),$$

其中关于$h(z)$ 的不等式利用了关系式(9)。整理得

$$h\big(x - t\, G_t(x)\big) \leq h(z) - \big(G_t(x) - \nabla f(x)\big)^T \big(z - x + t\, G_t(x)\big), \tag{12}$$

$$f(x) \leq f(z) - \nabla f(x)^T (z - x). \tag{13}$$

收敛性分析

将(11)–(13)式相加可得对任意$z \in \operatorname{dom}\psi$ 有

$$\psi\big(x - t\,G_t(x)\big) \le \psi(z) + G_t(x)^T(x - z) - \frac{t}{2}\|G_t(x)\|^2. \tag{14}$$

因此，对于每一步的迭代，记

$$\tilde{x} = x - t\,G_t(x),$$

在全局不等式(14)中，取$z = x^*$ 有

$$\begin{aligned}
\psi(\tilde{x}) - \psi^* &\le G_t(x)^T(x - x^*) - \frac{t}{2}\|G_t(x)\|^2 \\
&= \frac{1}{2t}\Big(\|x - x^*\|^2 - \big\|x - x^* - t\,G_t(x)\big\|^2\Big) \\
&= \frac{1}{2t}\Big(\|x - x^*\|^2 - \|\tilde{x} - x^*\|^2\Big).
\end{aligned}$$

收敛性分析

分别取$x = x^{i-1}$，$\tilde{x} = x^i$，$t = t_i = \frac{1}{L}$，$i = 1, 2, \cdots, k$，代入上面不等式并累加，

$$\begin{aligned}\sum_{i=1}^{k}\left(\psi(x^i) - \psi^*\right) &\leq \frac{1}{2t}\sum_{i=1}^{k}\left(\|x^{i-1} - x^*\|^2 - \|x^i - x^*\|^2\right)\\ &= \frac{1}{2t}\left(\|x^0 - x^*\|^2 - \|x^k - x^*\|^2\right)\\ &\leq \frac{1}{2t}\|x^0 - x^*\|^2.\end{aligned}$$

注意到在不等式(14)中，取$z = x$ 即可得到算法为下降法：

$$\psi(\tilde{x}) \leq \psi(x) - \frac{t}{2}\|G_t(x)\|^2,$$

即$\psi(x^i)$ 为非增的，因此

$$\psi(x^k) - \psi^* \leq \frac{1}{k}\sum_{i=1}^{k}\left(\psi(x^i) - \psi^*\right) \leq \frac{1}{2kt}\|x^0 - x^*\|^2.$$

收敛性分析

在上述定理中，收敛性要求步长小于或等于∇f 对应的利普希茨常数L的倒数。但是在实际应用中，我们经常很难知道L，因此可以考虑线搜索的技巧。注意到之所以需要$t \leq \frac{1}{L}$ 的条件是因为不等式(11)，所以线搜索策略可以是从某个$t = \hat{t} > 0$ 开始进行回溯$(t \leftarrow \beta t)$，直到满足不等式(11)。类似地，可以得到如下收敛性定理：

定理：邻近梯度法的收敛性

在假设8.1下，从某个$t = \hat{t} > 0$ 开始进行回溯$(t \leftarrow \beta t)$直到满足不等式(11)，设$\{x^k\}$ 是由迭代格式(7)产生的序列，则

$$\psi(x^k) - \psi^* \leq \frac{1}{2k \min\{\hat{t}, \beta/L\}} \|x^0 - x^*\|^2.$$

Lasso

- 考虑问题(Lasso)

$$\min_{x\in\Re^n} \frac{1}{2}\|Ax-b\|_2^2+\gamma\|x\|_1$$

其中$A\in\Re^{m\times n}$和$\gamma>0$

- proximal gradient method:

$$x^{k+1}=\mathbf{prox}_{t_k\gamma\|\cdot\|_1}(x^k-t_kA^T(Ax^k-b))$$

投影梯度法

- 考虑问题

$$\min_{x\in C} f(x) \quad \Leftrightarrow \quad \min_{x} f(x) + 1_C(x)$$

- 投影梯度法

$$x^{k+1} = \Pi_C(x^k - t_k \nabla f(x^k))$$

- 若$C = \Re^n_+$,则$\Pi_C(x) = x_+$
- 若$C = \{x | l \leq x \leq u\}$,则

$$(\Pi_C(x))_i = \begin{cases} l_i & x_i \leq l_i \\ x_i & l_i < x_i < u_i \\ u_i & x_i \geq u_i \end{cases}$$

内容回顾

考虑复合优化问题

$$\min_{x\in\mathbb{R}^n} \psi(x) = f(x) + h(x)$$

- $f(x)$：凸、连续可微，梯度∇f L-Lipschitz连续
- $h(x)$：正常闭凸函数，可以非光滑

- 邻近梯度法：收敛速度$\mathbf{O}\left(\frac{\mathbf{1}}{\mathbf{k}}\right)$
- FISTA：Nesterov加速邻近梯度版本，收敛速度提升到$\mathbf{O}\left(\frac{\mathbf{1}}{\mathbf{k^2}}\right)$

FISTA原始迭代格式

FISTA(Fast Iterative Shrinkage-Thresholding Algorithm)由两步构成：外推得到参考点y^k，再做邻近梯度迭代。

$$\begin{cases} y^k = x^{k-1} + \dfrac{k-2}{k+1}\left(x^{k-1} - x^{k-2}\right), \\ x^k = \operatorname{prox}_{t_k h}\left(y^k - t_k \nabla f(y^k)\right). \end{cases}$$

- t_k：步长，固定步长可取$t_k = t \leq \dfrac{1}{L}$
- 每一步计算量和邻近梯度法几乎不变；收敛速度由$O(1/k) \to O(1/k^2)$：设x^*为最优解，

$$[\psi(x^k)] - [\psi(x^*)] \leq \frac{2L}{(k+1)^2}\|x^0 - x^*\|^2.$$